



Deep learning

Projet IA générative



Mastère Data scientist

Antoine Vacavant

antoine.vacavant@ynov.com

antoine.vacavant@nxv.fr

Attendus

- Projet noté individuel
- A rendre :
 - Codes produits (Python, etc.)
 - Lien vers hébergement si disponible
 - Readme avec technos mises en place
 - Vidéos démos
- Objectif : développer une interface simple d'interaction avec un modèle de langage
 - Projet libre
 - Trouver des ressources pertinentes pour son projet

Hugging Face

- Plateforme de partage de
 - Datasets
 - Modèles
 - Codes



Hugging Face

- Plus de détails ici :

→ <https://huggingface.co/>



Hugging Face

Models

Datasets

Spaces

Posts

Docs

Pricing

Exemple de code

```
# Module for loading HF pre-trained models
from transformers import AutoModelForCausalLM, AutoTokenizer

# Pre-trained LLM, here with tiny stories
model = AutoModelForCausalLM.from_pretrained('roneneldan/TinyStories-1M')

# Tokenization
tokenizer = AutoTokenizer.from_pretrained("EleutherAI/gpt-neo-125M")

# Init prompt
prompt = "Once upon a time there was a little kid named "

# Encode the prompt with tokenizer
input_ids = tokenizer.encode(prompt, return_tensors="pt")

# Generate output
output = model.generate(input_ids, max_length = 1000, num_beams=1)

# Decode the result and print it
output_text = tokenizer.decode(output[0], skip_special_tokens=True)
print(output_text)
```

NVIDIA NIM

- Plateforme de partage de
 - Modèles
 - Containers
 - Ressources



- Plus de détails ici :

→ <https://catalog.ngc.nvidia.com/>

→ <https://build.nvidia.com/explore/>

- Besoin d'une **clé API** pour utiliser les modèles

Exemple de code

```
from openai import OpenAI

# OpenAI base model
client = OpenAI(
    base_url = "https://integrate.api.nvidia.com/v1",
    api_key = "YOUR_API_KEY" # A remplacer avec VOTRE clé
)

# Chat model with prompt
completion = client.chat.completions.create(
    model="meta/llama3-70b-instruct",
    messages=[{"role": "user", "content": "Hey! how are you doing?"}],
    temperature=0.5,
    top_p=0.7,
    max_tokens=1024,
    stream=True
)

# Result
for chunk in completion:
    if chunk.choices[0].delta.content is not None:
        print(chunk.choices[0].delta.content, end="")
```

Démarche

- Projet libre
- Prendre inspiration de codes et datasets disponibles
- Charger une IA générative depuis Hugging Face ou NVIDIA NGC (modules Python `openai`, `transformers`)
- Images, textes, sons, etc.
- Développer l'interface pour échanger avec le modèle
- Différents frameworks possibles (streamlit, ...)
- Si possible, héberger le produit final
- Dans tous les cas : produire des vidéos de démo

Go

A vous de jouer !